




UFMS

**UNIVERSIDADE
FEDERAL DE
MATO GROSSO DO SUL**

Teoria de Sistemas Lineares

Aula 05

Prof. Dr. Bruno Sereni

Teoria de Sistemas Lineares

Definições Básicas



Matrizes

Denotaremos por $A \in \mathbb{R}^{n \times m}$ uma matriz real, com n linhas e m colunas:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1(m-1)} & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2(m-1)} & a_{2m} \\ \vdots & \vdots & \cdots & \vdots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{n(m-1)} & a_{nm} \end{bmatrix}$$

- Neste caso, cada um dos a_{ij} , com $i = 1, 2, \dots, n$ e $j = 1, 2, \dots, m$, pertence ao conjunto dos números reais $\mathbb{R}$.
- Note que termos em **negrito** expressam matrizes.



Matrizes

Também podemos representar matrizes em termos de suas **linhas** ou suas **colunas**.

→ Sejam $A \in \mathbb{R}^{n \times m}$, $B \in \mathbb{R}^{m \times r}$, $C \in \mathbb{R}^{l \times n}$ e $D \in \mathbb{R}^{r \times p}$. Então, se $\mathbf{a}_i$ for a i -ésima **coluna** de A , e $\mathbf{b}_j$ for a j -ésima **linha** de B :

$$AB = [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_m] \begin{bmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \\ \vdots \\ \mathbf{b}_m \end{bmatrix} = \mathbf{a}_1 \mathbf{b}_1 + \mathbf{a}_2 \mathbf{b}_2 + \cdots + \mathbf{a}_m \mathbf{b}_m$$

Note que $\mathbf{a}_i \mathbf{b}_j$ é uma matriz $n \times r$.

AB estabelece uma **combinação** das colunas de A , a partir das linhas de B .



Matrizes

Simples Verificação:

$$\text{Sejam } A = \begin{bmatrix} 2 & -1 & 0 \\ 3 & 2 & 2 \end{bmatrix} \text{ e } B = \begin{bmatrix} 5 & 1 \\ 1 & 2 \\ -3 & 0 \end{bmatrix}$$

Então:

$$\mathbf{a}_1 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} -1 \\ 2 \end{bmatrix}, \mathbf{a}_3 = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \text{ e } \mathbf{b}_1 = [5 \quad 1], \mathbf{b}_2 = [1 \quad 2] \text{ e } \mathbf{b}_3 = [-3 \quad 0]$$

Assim:

$$AB = \mathbf{a}_1 \mathbf{b}_1 + \mathbf{a}_2 \mathbf{b}_2 + \mathbf{a}_3 \mathbf{b}_3 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} [5 \quad 1] + \begin{bmatrix} -1 \\ 2 \end{bmatrix} [1 \quad 2] + \begin{bmatrix} 0 \\ 2 \end{bmatrix} [-3 \quad 0]$$

$$AB = \begin{bmatrix} 10 & 2 \\ 15 & 3 \end{bmatrix} + \begin{bmatrix} -1 & -2 \\ 2 & 4 \end{bmatrix} + \begin{bmatrix} 0 & 0 \\ -6 & 0 \end{bmatrix} = \begin{bmatrix} 9 & 0 \\ 11 & 7 \end{bmatrix}$$



Matrizes

→ Note que também vale:

$$\mathbf{CA} = \mathbf{C}[\mathbf{a}_1 \quad \mathbf{a}_2 \quad \cdots \quad \mathbf{a}_m] = [\mathbf{Ca}_1 \quad \mathbf{Ca}_2 \quad \cdots \quad \mathbf{Ca}_m]$$

- Lembrando que $\mathbf{C} \in \mathbb{R}^{l \times n}$ e $\mathbf{A} \in \mathbb{R}^{n \times m}$, então $\mathbf{CA} \in \mathbb{R}^{l \times m}$.
- Cada coluna de $\mathbf{A}$ tem dimensão $n \times 1$.
- Portanto $\mathbf{Ca}_j \in \mathbb{R}^{l \times 1}$, ou seja, os produtos $\mathbf{Ca}_j$ serão **colunas** com l linhas.
- Agrupadas lado a lado, as m colunas $\mathbf{a}_j$ resultam em uma matriz com l linhas e m colunas
- **Resultado:** transformação $\mathbf{C}$ aplicada às **colunas** de $\mathbf{A}$.



Matrizes

→ Por fim, também é verdade que:

$$\mathbf{B}\mathbf{D} = \begin{bmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \\ \vdots \\ \mathbf{b}_m \end{bmatrix} \mathbf{D} = \begin{bmatrix} \mathbf{b}_1\mathbf{D} \\ \mathbf{b}_2\mathbf{D} \\ \vdots \\ \mathbf{b}_m\mathbf{D} \end{bmatrix}$$

- Agora, como $\mathbf{B} \in \mathbb{R}^{m \times r}$ e $\mathbf{D} \in \mathbb{R}^{r \times p}$, então $\mathbf{B}\mathbf{D} \in \mathbb{R}^{m \times p}$.
- Cada linha de $\mathbf{B}$ tem dimensão $1 \times r$.
- Portanto $\mathbf{b}_i\mathbf{D} \in \mathbb{R}^{1 \times p}$, ou seja, os produtos $\mathbf{b}_i\mathbf{D}$ serão **linhas** com l linhas.
- Agrupadas lado a lado, as m linhas $\mathbf{b}_i\mathbf{D}$ resultam em uma matriz com m linhas e p colunas.
- **Resultado:** transformação $\mathbf{D}$ aplicada às **linhas** de $\mathbf{B}$.

Teoria de Sistemas Lineares

Bases, Representações e Ortonormalização



Combinações Lineares

Se dissermos que $\mathcal{R}^n$ é um espaço linear real n -dimensional, então todo **vetor** que pertença a $\mathcal{R}^n$ é uma n -upla de números reais tais como

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

a qual também pode ser representada como $\mathbf{x} = [x_1 \quad x_2 \quad \cdots \quad x_n]'$, de forma que $(')$ indica a operação de **transposição**.



Combinações Lineares

Dizemos que um conjunto de vetores $\{x_1, x_2, \dots, x_m\} \in \mathcal{R}^n$ é dito **linearmente dependente (LD)** se existirem números reais $\alpha_1, \alpha_2, \dots, \alpha_n$, nem todos nulos, tais que

$$\alpha_1 x_1 + \alpha_2 x_2 + \dots + \alpha_m x_m = 0$$

Caso a igualdade acima seja válida apenas se $\alpha_1 = \alpha_2 = \dots = \alpha_m = 0$, então dizemos que o conjunto de vetores $\{x_1, x_2, \dots, x_m\}$ é dito ser **linearmente independente (LI)**.



Combinações Lineares

Na prática, se um conjunto de vetores é **LD**, então isso significa que deve existir pelo menos um α_i que não seja nulo.

Assim, se por acaso $\alpha_1 \neq 0$, então veja que podemos fazer:

$$\begin{aligned} \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \alpha_3 \mathbf{x}_3 + \cdots + \alpha_m \mathbf{x}_m &= \mathbf{0} \Rightarrow \\ \mathbf{x}_1 &= -\frac{1}{\alpha_1} (\alpha_2 \mathbf{x}_2 + \alpha_3 \mathbf{x}_3 + \cdots + \alpha_m \mathbf{x}_m) =: \beta_2 \mathbf{x}_2 + \beta_3 \mathbf{x}_3 \cdots + \beta_m \mathbf{x}_m \end{aligned}$$

onde $\beta_i = -\alpha_i/\alpha_1$.

Dizemos que, $\mathbf{x}_1$ é uma **combinação linear** de $\mathbf{x}_2, \mathbf{x}_3, \dots, \mathbf{x}_m$,



Combinações Lineares

Por fim, a **dimensão** de um espaço linear é definida em termos do **número máximo de vetores LI** que existem neste espaço.

Exemplo 1. Em um espaço $\mathcal{R}^4$, que portanto possui dimensão $n = 4$, poderemos formar, no máximo, conjuntos com 4 vetores LI.



Base

Um conjunto de vetores LI em $\mathcal{R}^n$ é chamado de **base** se todo vetor $x \in \mathcal{R}^n$ puder ser representado de forma única como uma combinação linear deste conjunto.

Em $\mathcal{R}^n$, qualquer conjunto de vetores LI pode ser usado como base. Seja $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$ um desses conjuntos.

Então, qualquer vetor x pode ser expresso unicamente como

$$x = \alpha_1 \mathbf{q}_1 + \alpha_2 \mathbf{q}_2 + \dots + \alpha_n \mathbf{q}_n$$



Representações

Se definirmos uma matriz quadrada $n \times n$ formada como os vetores $\mathbf{q}_i$ que constituem uma base em $\mathcal{R}^n$:

$$\mathbf{Q} =: [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n]$$

Então, podemos escrever

$$x = \alpha_1 \mathbf{q}_1 + \alpha_2 \mathbf{q}_2 + \cdots + \alpha_n \mathbf{q}_n = \mathbf{Q} \begin{bmatrix} \alpha_1 \\ \alpha_2 \\ \vdots \\ \alpha_n \end{bmatrix} = \mathbf{Q} \bar{x}$$

→ Dizemos que $\bar{x} = [\alpha_1 \ \alpha_2 \ \cdots \ \alpha_n]'$ é uma **representação** de x com respeito à base $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$.



Base Ortonormal

A cada espaço linear $\mathcal{R}^n$ podemos associar a seguinte base:
 $\{\mathbf{i}_1, \mathbf{i}_2, \dots, \mathbf{i}_{n-1}, \mathbf{i}_n\}$, sendo

$$\mathbf{i}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}, \mathbf{i}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \\ 0 \end{bmatrix}, \dots, \mathbf{i}_{n-1} = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \\ 0 \end{bmatrix}, \mathbf{i}_n = \begin{bmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 0 \\ 1 \end{bmatrix}$$

→ Esta base é chamada de **base ortonormal**.



Base Ortonormal

Assim, com respeito à base ortonormal, para qualquer vetor $x \in \mathcal{R}^n$ teremos:

$$x := \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \mathbf{i}_1 + x_2 \mathbf{i}_2 + \cdots + x_{n-1} \mathbf{i}_{n-1} + x_n \mathbf{i}_n$$

Agrupando os vetores da base ortonormal em uma matriz quadrada:

$$Q = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{bmatrix} = \mathbf{I}_n \rightarrow \text{matriz identidade } n \times n$$



Base Ortonormal


Portanto:

$$\mathbf{x} =: \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = x_1 \mathbf{i}_1 + x_2 \mathbf{i}_2 + \cdots + x_{n-1} \mathbf{i}_{n-1} + x_n \mathbf{i}_n = \mathbf{I}_n \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

→ Ou seja, a representação de qualquer vetor $\mathbf{x}$ com respeito à base ortonormal é **igual a ele mesmo**.

Bases e Representações

Exemplo 2. Considere o vetor $x = [1 \ 3]'$ em $\mathcal{R}^2$ mostrado na figura abaixo. Os vetores $q_1 = [3 \ 1]'$ e $q_2 = [2 \ 2]'$ são LI, e portanto, podem ser usados como uma base.



Traçando retas paralelas aos vetores q_1 e q_2 , a partir de x , vemos que estas fazem interseção em $-q_1$ e $2q_2$. Portanto, a **representação** de x com respeito a base $\{q_1, q_2\}$ é $[-1 \ 2]'$, ou seja:

$$x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} = Q\bar{x} = [q_1 \ q_2] \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix} = \begin{bmatrix} 3 & 2 \\ 1 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \end{bmatrix}$$



Bases e Representações

Exercício. Verifique que a representação de $x = [1 \ 3]'$ com respeito à base $\{q_2, i_2\}$ é $\bar{x} = [0,5 \ 2]'$.

$$q_1 = [3 \ 1]' \text{ e } q_2 = [2 \ 2]'$$



Norma de Vetores

O conceito de **norma** nada mais é do que a generalização da ideia de comprimento ou magnitude. Ou seja, trata-se de uma **medida do “tamanho” de um vetor**.

→ A norma de um vetor x é qualquer função real de x , **denotada por $\|x\|$** que apresente as seguintes propriedades:

1. *A norma de x é **positiva ou nula**, e será nula apenas se x for nulo.*
2. *O **escalamento** de um vetor **implica em um escalamento absoluto da norma**.*
3. *A norma da soma de dois vetores é sempre **menor ou igual** a soma das normas destes mesmos vetores.*



Norma de Vetores

Matematicamente, estas propriedades se traduzem como:

1. $\|x\| \geq 0, \forall x$ e $\|x\| = 0 \Leftrightarrow x = \mathbf{0}$.
2. $\|\alpha x\| = |\alpha| \|x\|, \quad \forall \alpha \in \mathbb{R}$.
3. $\|x_1 + x_2\| \leq \|x_1\| + \|x_2\|, \forall x_1, x_2$

A terceira desigualdade é conhecida na literatura como **desigualdade triangular**.



Norma de Vetores

Sendo $\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_n]'$, então a norma de $\mathbf{x}$ pode ser escolhida a partir de qualquer uma das seguintes opções:

$$\|\mathbf{x}\|_1 := \sum_{i=1}^n |\mathbf{x}_i| \rightarrow \text{Norma 1}$$

$$\|\mathbf{x}\|_2 := \sqrt{\mathbf{x}'\mathbf{x}} = \left(\sum_{i=1}^n |\mathbf{x}_i|^2 \right)^{1/2} \rightarrow \text{Norma 2 (ou Euclidiana)}$$

$$\|\mathbf{x}\|_\infty := \max_i |\mathbf{x}_i| \rightarrow \text{Norma Infinito}$$

OBS: A norma 2 é o comprimento do vetor a partir da origem. Usaremos esta ao longo do curso, e por simplicidade, o índice 2 será omitido.



Vetores Ortonormais

Um vetor x é chamado de **normalizado** quando sua norma Euclidiana é igual a 1 ou, equivalentemente, $x'x = 1$.

Dois vetores x_1 e x_2 são **ortogonais** se $x_1'x_2 = x_2'x_1 = 0$.

Um conjunto de vetores x_i , $i = 1, 2, \dots, m$ é dito **ortonormal** quando

$$x_i'x_j = \begin{cases} 0, & \text{se } i \neq j \\ 1, & \text{se } i = j \end{cases}$$

→ Ou seja, $\{x_1, x_2, \dots, x_m\}$ são **ortonormais** se cada vetor x_i é normalizado, e todos os vetores x_i são ortogonais entre si.



Ortonormalização

Para um dado conjunto de vetores LI $\{e_1, e_2, \dots, e_m\}$, podemos encontrar um conjunto ortonormal realizando o seguinte procedimento:

- 1) Defina $u_1 := e_1$
- 2) Normalize o vetor u_1 , obtendo* o vetor normalizado $q_1 := u_1 / \|u_1\|$.




*Lembre-se: a forma polar do vetor x é $x = \|x\| \angle \theta$, onde $\|x\|$ é a norma 2 de x , e θ o ângulo (ou fase) de x .

Ortonormalização

3) Defina $u_2 := e_2 - (q_1' e_2) q_1$


→ $(q_1' e_2) q_1$ é a projeção de e_2 ao longo de q_1 .



Ortonormalização

3) Defina $u_2 := e_2 - (q_1' e_2) q_1$

→ Subtraindo $(q_1' e_2) q_1$ de e_2 , sobra apenas a **parte vertical** de e_2 .




Ortonormalização

3) Defina $\mathbf{u}_2 := \mathbf{e}_2 - (q_1' \mathbf{e}_2) \mathbf{q}_1$

4) Normalize o vetor $\mathbf{u}_2$, fazendo $\mathbf{q}_2 := \mathbf{u}_2 / \|\mathbf{u}_2\|$

→ Ao final, obtemos $\mathbf{q}_2$, um vetor normalizado e ortogonal à $\mathbf{q}_1$. Portanto, $\mathbf{q}_1$ e $\mathbf{q}_2$ são **ortonormais**.




Ortonormalização

5) Prosseguindo, defina $\mathbf{u}_3 := \mathbf{e}_3 - (\mathbf{q}'_1 \mathbf{e}_3) \mathbf{q}_1 - (\mathbf{q}'_2 \mathbf{e}_3) \mathbf{q}_2$

→ Aqui, estamos no $\mathcal{R}^3$:

→ $(\mathbf{q}'_1 \mathbf{e}_3) \mathbf{q}_1$ é a projeção de $\mathbf{e}_3$ ao longo de $\mathbf{q}_1$.




Ortonormalização

5) Prosseguindo, defina $\mathbf{u}_3 := \mathbf{e}_3 - (\mathbf{q}'_1 \mathbf{e}_3) \mathbf{q}_1 - (\mathbf{q}'_2 \mathbf{e}_3) \mathbf{q}_2$

→ Aqui, estamos no $\mathcal{R}^3$:

→ $(\mathbf{q}'_1 \mathbf{e}_3) \mathbf{q}_1$ é a projeção de $\mathbf{e}_3$ ao longo de $\mathbf{q}_1$.


→ $(\mathbf{q}'_2 \mathbf{e}_3) \mathbf{q}_2$ é a projeção de $\mathbf{e}_3$ ao longo de $\mathbf{q}_2$.



Ortonormalização

5) Prosseguindo, defina $\mathbf{u}_3 := \mathbf{e}_3 - (\mathbf{q}_1' \mathbf{e}_3) \mathbf{q}_1 - (\mathbf{q}_2' \mathbf{e}_3) \mathbf{q}_2$

→ Subtraindo $(\mathbf{q}_1' \mathbf{e}_3) \mathbf{q}_1$ e $(\mathbf{q}_2' \mathbf{e}_3) \mathbf{q}_2$ de $\mathbf{e}_3$ sobra apenas a **componente vertical, $\mathbf{u}_3$** :




Ortonormalização

5) Prosseguindo, defina $\mathbf{u}_3 := \mathbf{e}_3 - (\mathbf{q}'_1 \mathbf{e}_3) \mathbf{q}_1 - (\mathbf{q}'_2 \mathbf{e}_3) \mathbf{q}_2$

6) Normalize o vetor $\mathbf{u}_3$, fazendo $\mathbf{q}_3 := \mathbf{u}_3 / \|\mathbf{u}_3\|$

→ Ao final, obtemos $\mathbf{q}_3$, um vetor normalizado e ortogonal à $\mathbf{q}_1$ e a $\mathbf{q}_2$.

Portanto, $\mathbf{q}_1$, $\mathbf{q}_2$ e $\mathbf{q}_3$ são **ortonormais**.





Ortonormalização

Prosseguimos aplicando o mesmo procedimento, de modo que o m -ésimo componente do conjunto de vetores ortonormais é dado por

$$\mathbf{q}_m := \mathbf{u}_m / \|\mathbf{u}_m\|$$

onde

$$\mathbf{u}_m := \mathbf{e}_m - \sum_{k=1}^{m-1} (\mathbf{q}'_k \mathbf{e}_m) \mathbf{q}_k$$

→ Este método é conhecido como **procedimento de ortonormalização de Schmidt**.



Ortonormalização

Seja $A = [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_m]$ uma matriz $n \times m$, com $m \leq n$ (nº de colunas menor ou igual ao nº de linhas).

Se todas as colunas $\mathbf{a}_i$ de A são ortonormais, então

$$A' A = \begin{bmatrix} \mathbf{a}'_1 \\ \mathbf{a}'_2 \\ \vdots \\ \mathbf{a}'_m \end{bmatrix} [\mathbf{a}_1 \ \mathbf{a}_2 \ \cdots \ \mathbf{a}_m] = \mathbf{I}_m$$

OBS: Este resultado advém da definição da ortonormalidade: $\mathbf{a}'_i \mathbf{a}_j = 1$, se $j = i$, e $\mathbf{a}'_i \mathbf{a}_j = 0$ se $j \neq i$.

Teoria de Sistemas Lineares

Equações Algébricas Lineares



Equações Algébricas Lineares

Considere o conjunto de equações algébricas lineares

$$Ax = y$$

onde A é uma matriz real de dimensão $m \times n$, enquanto y e x são vetores de dimensões $m \times 1$ e $n \times 1$, respectivamente.

→ A e y são dados, enquanto x é a variável a ser encontrada.

Nestes termos, o conjunto consiste em m equações e n incógnitas.

Iremos discutir as **condições de existência** e a **forma geral das soluções** destas equações.



Equações Algébricas Lineares

Para isso, precisamos fazer algumas definições:

- O **espaço coluna** de uma matriz A ($\text{Im}(A)$) é definido como todas as possíveis combinações lineares das colunas de A .
- O **posto** de A ($\text{rank}(A)$ ou $\rho(A)$) é a dimensão do espaço coluna de A , ou seja, o número de colunas LI em A .
- O vetor x é chamado **vetor nulo** de A se $Ax = 0$.
- O **núcleo** de A ($\text{ker}(A)$) consiste em todos os vetores nulos de A .
- A **nulidade** de A ($\text{nullity}(A)$ ou $\dim(\text{ker}(A))$) é a dimensão do núcleo de A , isto é, o número de vetores nulos LI de A .

Relação fundamental (posto-nulidade):

$$n = \text{rank}(A) + \text{nullity}(A)$$

sendo n o número de colunas de A .



Equações Algébricas Lineares

Exemplo 3. Considere a matriz

$$A = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \end{bmatrix} =: [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \mathbf{a}_3 \quad \mathbf{a}_4]$$

Veja que $\mathbf{a}_1$ e $\mathbf{a}_2$ são LI. Já $\mathbf{a}_3$ e $\mathbf{a}_4$ podem ser escritas como combinações lineares de $\mathbf{a}_1$ e $\mathbf{a}_2$:

$$\mathbf{a}_3 = \mathbf{a}_1 + \mathbf{a}_2 \Rightarrow \mathbf{a}_1 + \mathbf{a}_2 - \mathbf{a}_3 = 0$$

$$\mathbf{a}_4 = 2\mathbf{a}_2 \Rightarrow 2\mathbf{a}_2 - \mathbf{a}_4 = 0$$



Equações Algébricas Lineares

Como A tem **duas colunas LI**, $\text{rank}(A) = 2$.

Assim, o conjunto $\{a_1, a_2\}$ pode ser usado como uma **base** para o **espaço coluna de A** . Ou seja:

→ a CL $\alpha_1 a_1 + \alpha_2 a_2$, com $\alpha_1, \alpha_2 \in \mathbb{R}$ define todos os vetores pertencentes a um **plano** em $\mathbb{R}^3$ que podem ser formados a partir das colunas de A .

O fato de $\text{rank}(A) = 2$ indica que o espaço coluna de A é um subespaço de $\mathbb{R}^3$, isto é, um **plano** passando pela origem.



Equações Algébricas Lineares

Ainda, da relação fundamental (posto-nulidade):

$$\text{nullity}(\mathbf{A}) = n - \text{rank}(\mathbf{A}) = 4 - 2 = 2$$

De forma equivalente, como a **nulidade de $\mathbf{A}$ é 2**, então o núcleo de $\mathbf{A}$ tem **dimensão 2**. Ou seja, existem dois vetores LI, pertencentes ao núcleo de $\mathbf{A}$, e estes são capazes de gerar **todos os vetores nulos de $\mathbf{A}$** .



Equações Algébricas Lineares

Pode-se verificar que $\mathbf{n}_1 = [1 \ 1 \ -1 \ 0]'$ e $\mathbf{n}_2 = [0 \ 2 \ 0 \ -1]$ atendem a condição $A\mathbf{n}_i = \mathbf{0}$, e portanto, são vetores nulos de A .

De fato:

$$A\mathbf{n}_1 = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 + 2 - 3 \\ 1 + 2 - 3 \\ 2 - 2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0}$$

$$A\mathbf{n}_2 = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 2 \\ 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 2 - 2 \\ 4 - 4 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0}$$



Equações Algébricas Lineares

Além disso, veja que $\mathbf{n}_1$ e $\mathbf{n}_2$ são LI, e portanto, podem formar uma base para o núcleo de A .

Ou seja, qualquer $\mathbf{x} \in \mathcal{R}^4$ tal que $A\mathbf{x} = \mathbf{0}$ pode ser escrito como

$$\mathbf{x} = \alpha_1 \mathbf{n}_1 + \alpha_2 \mathbf{n}_2 = \alpha_1 \begin{bmatrix} 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 0 \\ 2 \\ 0 \\ -1 \end{bmatrix}$$

com α_1, α_2 reais.



Equações Algébricas Lineares

Na prática, para a matriz A considerada neste exemplo:

- qualquer $\mathbf{y} \in \mathbb{R}^3$ tal que $A\mathbf{x} = \mathbf{y}$ pode ser escrito como

$$\mathbf{y} = \alpha_1 \mathbf{a}_1 + \alpha_2 \mathbf{a}_2 = \alpha_1 \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix} + \alpha_2 \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} \quad (\text{espaço coluna de } A)$$

- qualquer $\mathbf{x} \in \mathbb{R}^4$ tal que $A\mathbf{x} = \mathbf{0}$ pode ser escrito como

$$\mathbf{x} = \beta_1 \mathbf{n}_1 + \beta_2 \mathbf{n}_2 = \beta_1 \begin{bmatrix} 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} + \beta_2 \begin{bmatrix} 0 \\ 2 \\ 0 \\ -1 \end{bmatrix} \quad (\text{núcleo de } A)$$

com $\alpha_1, \alpha_2, \beta_1, \beta_2$ sendo escalares reais.

Isso é de fato muito interessante e importante!



Equações Algébricas Lineares

Ainda sobre o posto de matrizes:

- Embora $\text{rank}(A)$ seja definido como o número de colunas LI de A , **$\text{rank}(A)$ também é igual ao número de linhas LI de A .**
- Isso gera duas **conclusões importantes**:
 - 1) o número de colunas LI é sempre igual ao número de linhas LI (óbvio);
 - 2) Se A é $m \times n$, então $\text{rank}(A) \leq \min(m, n)$.

Uma matriz $A \in \mathcal{R}^{2 \times 3}$ terá posto, no máximo, igual a 2. Pois, se houverem 2 linhas LI, necessariamente, só podem haver 2 colunas LI. Veja que se houvessem 3 colunas LI, seria necessária haver 2 linhas LI, o que é impossível neste pequeno exemplo.



Equações Algébricas Lineares

Usando o MATLAB:

```
a=[0 1 1 2;1 2 3 4;2 0 2 0];
```

```
rank(a)
```

fornece resultado 2, como já constatado.

Ainda, usando

```
R=orth(a)
```

retorna

R =

```
-0.3782    0.3084  
-0.8877    0.1468  
-0.2627   -0.9399
```

As colunas de R formam uma base ortonormal de A .



Equações Algébricas Lineares

→ É possível verificar que a base encontrada é *diferente* aquela obtida usando procedimento de ortonormalização de Schimidt a partir de $\{a_1, a_2\}$, encontrada anteriormente, em função do algoritmo usado pelo MATLAB. No entanto, ambas devem gerar o mesmo espaço coluna.

→ De fato, fazendo

$$\text{rank}([a1 \ a2 \ R])$$

fornece resultado 2.

→ Isso indica que, apesar de a_1 e a_2 serem LI, assim como as colunas de R, a concatenação dos 4 vetores não aumenta o posto, indicando que uma está no espaço coluna gerado pela outra.



Equações Algébricas Lineares

→ A análise do **núcleo** da matriz A também pode ser feita via MATLAB. Utilizando

$$N = \text{null}(a)$$

obtemos

$N =$

```

0.5992    0.3091
0.5299   -0.7331
-0.5992   -0.3091
0.0347    0.5211
  
```

As colunas de N formam uma base ortonormal para o núcleo de A . As mesmas observações que fizemos para o posto de A também valem aqui.



Equações Algébricas Lineares

Agora estamos prontos para discutir as soluções de $Ax = y$. Começamos enunciando o Teorema 3.1*, que estabelece condições para existência de uma solução x ao problema.

Teorema 3.1

1. *Dada uma matriz $A \in \mathcal{R}^{m \times n}$ e um vetor $y \in \mathcal{R}^{m \times 1}$, uma solução $x \in \mathcal{R}^{n \times 1}$ existe em $Ax = y$ se, e somente se, y pertence ao espaço coluna de A ou, equivalentemente,*

$$\rho(A) = \rho([A \ y])$$

onde $[A \ y]$ é uma matriz $m \times (n + 1)$, com y anexado à A como coluna adicional.

2. *Dada A , uma solução x existe em $Ax = y$ para todo y se, e somente se, A tem posto m (posto completo de linhas).*



Equações Algébricas Lineares

Vamos destrinchar os enunciados do Teorema 3.1:

→ Veja que o produto Ax pode ser visto como:

$$Ax = [a_1 \quad a_2 \quad a_3] \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = x_1 a_1 + x_2 a_2 + x_3 a_3 = y$$

→ Assim, y é justamente resultado de uma **combinação linear das colunas de y** , i.e., **y pertence ao espaço coluna de A** .

→ Logo, se y é uma CL das colunas de A , é imperativo que

$$\text{posto}(A) = \text{posto}([A \quad y])$$

Ou seja, adicionar y como uma coluna nova à A não aumenta o posto, uma vez que y não é LI das colunas de A .



Equações Algébricas Lineares

Vamos destrinchar os enunciados do Teorema 3.1:

- Agora, se $A \in \mathcal{R}^{m \times n}$ tiver posto completo de linhas, então
$$\text{posto}(A) = m$$
- Lembre-se: $\text{posto}(A) \leq \min(m, n)$. Assim, se $\text{posto}(A) = m$, adicionar colunas à A **não aumenta o posto**, pois este está “**travado**” pela restrição ($\text{posto}(A) = \text{posto}([A \ y])$).
- Geometricamente, isso significa que $\text{Im}(A) = \mathcal{R}^m$. Lembrando que $y \in \mathcal{R}^m$, então, o **espaço coluna de A compreende todo o espaço de y** (*i.e.* **y pertence ao espaço coluna de A**).



Equações Algébricas Lineares

Agora, o Teorema 3.2 apresenta para **unicidade** ou **multiplicidade** de soluções em $Ax = y$.

Teorema 3.2 (Parametrização de todas as soluções)

Dada uma matriz $A \in \mathcal{R}^{m \times n}$ e um vetor $y \in \mathcal{R}^{m \times 1}$, considere que x_p seja uma solução de $Ax = y$ e seja $k := n - \rho(A)$ a nulidade de A .

*Se A possuir posto n (posto completo de colunas) ou $k = 0$, então a **solução x_p é única**.*

Se $k > 0$, então para todo número real α_i , $i = 1, 2, \dots, k$, o vetor

$$x = x_p + \alpha_1 n_1 + \dots + \alpha_k n_k$$

***também é uma solução de $Ax = y$** , onde $\{n_1, \dots, n_k\}$ é uma base do núcleo de A .*



Equações Algébricas Lineares

Vamos destrinchar o enunciado do Teorema 3.2:

→ Veja que substituindo $\mathbf{x} = \mathbf{x}_p + \alpha_1 \mathbf{n}_1 + \cdots + \alpha_k \mathbf{n}_k$ em $A\mathbf{x} = \mathbf{y}$, temos:

$$\begin{aligned} A(\mathbf{x}_p + \alpha_1 \mathbf{n}_1 + \cdots + \alpha_k \mathbf{n}_k) &= A\mathbf{x}_p + A(\alpha_1 \mathbf{n}_1 + \cdots + \alpha_k \mathbf{n}_k) = \\ &= A\mathbf{x}_p + \sum_{i=1}^k \alpha_i A\mathbf{n}_i \end{aligned}$$

→ Como $\{\mathbf{n}_1, \cdots, \mathbf{n}_k\}$ formam uma base para o núcleo de A , então qualquer combinação linear destes vetores gera um vetor $\mathbf{n}$ tal que $A\mathbf{n} = \mathbf{0}$.



Equações Algébricas Lineares

→ Assim:

$$Ax_p + \sum_{i=1}^k \alpha_i An_i = Ax_p + \mathbf{0} = Ax_p = y$$

→ Na prática, somar $\alpha_1 n_1 + \dots + \alpha_k n_k$ à x_p produz infinitas novas soluções para $Ax = y$ (soluções múltiplas), para cada escolha de α_i .

→ Agora, se $\text{rank}(A) = n$, então $k = n - \text{rank}(A) = 0$ ou, equivalentemente, a **nulidade de A é 0**, então o **conjunto de vetores nulos de A é vazio**. Ou seja, **não existem vetores n_i que possam formar o somatório**.

→ **Conclusão:** a única solução do problema é x_p . (unicidade)



Equações Algébricas Lineares

→ Por outro lado, se assumirmos a existência de uma nova solução $\bar{x}$, então $A\bar{x} = y$. Portanto:

$$\begin{aligned} A\bar{x} - Ax_p &= y - y \Rightarrow \\ A(\bar{x} - x_p) &= 0 \end{aligned}$$

→ Isso implica no fato de que $\bar{x} - x_p$ deve pertencer ao núcleo de A . Para que $\ker(A) \neq \{\emptyset\}$, a nulidade de A deve ser diferente de 0, ou $k > 0$.



Equações Algébricas Lineares

Exemplo 4. Considere a equação

$$A\mathbf{x} = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \end{bmatrix} \mathbf{x} =: [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \mathbf{a}_3 \quad \mathbf{a}_4] \mathbf{x} = \begin{bmatrix} -4 \\ -8 \\ 0 \end{bmatrix} = \mathbf{y}$$

Aqui, podemos verificar que $\rho(A) = \rho([A \quad \mathbf{y}]) = 2$, implicando em $\mathbf{y} \in \text{Im}(A)$ (*i.e.* $\mathbf{y}$ pertence ao espaço coluna de A).

De fato, veja que $\mathbf{x}_p = [0 \quad -4 \quad 0 \quad 0]'$ é uma solução:

$$A\mathbf{x}_p = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 1 & 2 & 3 & 4 \\ 2 & 0 & 2 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ -4 \\ 0 \\ 0 \end{bmatrix} = 0 \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix} - 4 \begin{bmatrix} 1 \\ 2 \\ 0 \end{bmatrix} + 0 \begin{bmatrix} 1 \\ 3 \\ 2 \end{bmatrix} + 0 \begin{bmatrix} 2 \\ 4 \\ 0 \end{bmatrix} = \begin{bmatrix} -4 \\ -8 \\ 0 \end{bmatrix} = \mathbf{y}$$



Equações Algébricas Lineares

Utilizando a base para o núcleo de A , encontrada no Exemplo 2, podemos expressar a **solução geral do problema** como

$$\mathbf{x} = \mathbf{x}_p + \alpha_1 \mathbf{n}_1 + \alpha_2 \mathbf{n}_2 = \begin{bmatrix} 0 \\ -4 \\ 0 \\ 0 \end{bmatrix} + \alpha_1 \begin{bmatrix} 1 \\ 1 \\ -1 \\ 0 \end{bmatrix} + \alpha_2 \begin{bmatrix} 0 \\ 2 \\ 0 \\ -1 \end{bmatrix}$$

para quaisquer $\alpha_1, \alpha_2 \in \mathbb{R}$.



Determinante

Vimos que o posto de uma matriz é definido pelo número de colunas (ou linhas) LI. Veremos, agora, no caso de matrizes $n \times n$ (matrizes quadradas) que o posto também pode ser definido em função de outra propriedade das matrizes: o **determinante**.

→ Para matrizes 1×1 :

$$\det(a) = a$$

→ Para matrizes 2×2 :

$$\det(A) = a_{11}a_{22} - a_{21}a_{12}$$



Determinante

De forma geral, para matrizes $n \times n$, $n \geq 2$:

$$\det(\mathbf{A}) = \sum_i^n a_{ij} c_{ij}$$

onde a_{ij} denota a entrada na i -ésima linhas e j -ésima coluna de $\mathbf{A}$. O número c_{ij} é o **cofator** correspondente ao elemento a_{ij} , sendo

$$c_{ij} = (-1)^{i+j} \mathbf{M}_{ij},$$

em que $\mathbf{M}_{ij}$ é a *submatriz* $(n - 1) \times (n - 1)$ de $\mathbf{A}$, obtida ao se eliminar a i -ésima linha e j -ésima coluna.



Determinante

Exemplo 5. Considerando a matriz quadrada 3×3

$$A = \begin{bmatrix} 1 & 3 & -2 \\ 2 & 1 & 2 \\ 1 & -1 & 2 \end{bmatrix},$$

teremos, se escolhermos $j = 2$:

$$\det A = \sum_i^n a_{ij} c_{ij} = \sum_{i=1}^3 a_{i2} c_{i2}$$

Os cofatores serão c_{12} , c_{22} e c_{32} . Logo, precisaremos das matrizes:

$$M_{12} = \begin{bmatrix} 2 & 2 \\ 1 & 2 \end{bmatrix}, \quad M_{22} = \begin{bmatrix} 1 & -2 \\ 1 & 2 \end{bmatrix} \quad e \quad M_{32} = \begin{bmatrix} 1 & -2 \\ 2 & 2 \end{bmatrix}$$



Determinante

Calculando os determinantes:

$$\det M_{12} = \det \begin{bmatrix} 2 & 2 \\ 1 & 2 \end{bmatrix} = 4 - 2 = 2$$

$$\det M_{22} = \det \begin{bmatrix} 1 & -2 \\ 1 & 2 \end{bmatrix} = 2 - (-2) = 4$$

$$\det M_{32} = \det \begin{bmatrix} 1 & -2 \\ 2 & 2 \end{bmatrix} = 2 - (-4) = 6$$

Para, então, obter os cofatores

$$c_{12} = (-1)^{1+2} \det M_{12} = -2$$

$$c_{22} = (-1)^{2+2} \det M_{22} = 4$$

$$c_{32} = (-1)^{3+2} \det M_{32} = -6$$



Equações Algébricas Lineares

E, finalmente, calcular o determinante de $A = \begin{bmatrix} 1 & 3 & -2 \\ 2 & 1 & 2 \\ 1 & -1 & 2 \end{bmatrix}$:

$$\begin{aligned} \det A &= \sum_{i=1}^3 a_{i2} c_{i2} = (a_{12} c_{12} + a_{22} c_{22} + a_{32} c_{32}) = \\ &= (3(-2) + 1(4) + (-1)(-6)) \end{aligned}$$

$$\det A = 4$$

OBS: o mesmo resultado é obtido escolhendo $j = 1$ ou $j = 3$.



Determinante

Observe que, no caso de matrizes **diagonais** ou **triangulares**, o determinante pode ser calculado diretamente pelo **produto dos elementos na diagonal**. Ou seja, se

$$A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix} \quad \text{ou} \quad A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix}$$

tem-se

$$\det A = \prod_i^n a_{ii} = a_{11} \times a_{22} \times \cdots \times a_{nn}$$



Determinante

O determinante de qualquer submatriz $r \times r$ de A é chamado de **menor de ordem r** de A .

Importante: o determinante da própria matriz A ($\det A$) é *um menor de A* (no caso, menor de ordem 3).

Note que A é a submatriz de A , selecionando *todas as suas linhas e colunas*.



Determinante

No caso do Exemplo 5:

$$\det A = \det \begin{bmatrix} 1 & 3 & -2 \\ 2 & 1 & 2 \\ 1 & -1 & 2 \end{bmatrix}$$

- **é o menor de ordem 3** da matriz A .

$$\det M_{11} = \begin{bmatrix} 1 & 3 \\ 2 & 1 \end{bmatrix}, \det M_{12} = \begin{bmatrix} 2 & 2 \\ 1 & 2 \end{bmatrix}, \dots, \text{ e } \det M_{33} = \begin{bmatrix} 1 & 2 \\ -1 & 2 \end{bmatrix}$$

- **são menores de ordem 2** da matriz A .

$$\det[a_{11}] = 1, \det[a_{12}] = 3, \det[a_{13}] = 2, \dots, \det[a_{33}] = 2$$

- **são menores de ordem 1** da matriz A .



Determinante

O determinante de qualquer submatriz $r \times r$ de A é chamado de **menor de ordem r** de A .

→ A partir disto, o **posto** de uma matriz A pode ser definido como sendo a **maior ordem** dentre todos os **menores não nulos** de A .

Ainda, resgatando o Exemplo 5, dentre os menores não nulos de A , o de maior ordem é justamente o menor de ordem 3, $\det A$.

Portanto, $\text{rank}(A) = 3$



Matriz Não Singular

Uma matriz *quadrada* é chamada de **não singular** se e somente se o seu determinante é diferente de zero:

$$A \text{ é não singular} \Leftrightarrow \det A \neq 0$$

Consequentemente, a matriz quadrada $A \in \mathbb{R}^{n \times n}$ é **não singular**, se e somente se ter **posto completo de linhas (colunas)**.

Pelo o que vimos com determinantes, dizer que o **posto de A é r** significa, então, que **existe pelo menos um menor não nulo de ordem r** .

Isto é **$\text{rank}(A) = n$** , indicando que existe um menor não nulo de ordem n :
ou seja, $\det A \neq 0$.



Matriz Não Singular

Resumindo:

Seja A uma matriz quadrada $n \times n$. Então, se A for não singular, então as seguintes afirmativas são verdadeiras e equivalentes:

- $\det A \neq 0$;
- existe um menor de ordem n não nulo;
- $\text{rank}(A) = n$;



Matriz Inversa

A **inversa** de uma matriz não singular $A = [a_{ij}]$ é denotada por A^{-1} .

A matriz inversa apresenta as seguintes **propriedades**:

$$AA^{-1} = A^{-1}A = I,$$

e pode ser calculada através de

$$A^{-1} = \frac{Adj\ A}{\det A} = \frac{1}{\det A} [c_{ij}]'$$

onde $Adj = [c_{ij}]'$ é a transposta da matriz com os cofatores c_{ij} de A .



Matriz Inversa

Sobre a inversa, cabem as seguintes observações:

→ Se A for singular, então A não possui inversa.

*De fato: se A for singular, $\det A = 0$, implicando em **indeterminação** no cálculo da*

$$\text{inversa: } A^{-1} = \frac{\text{Adj } A}{\det A} = \frac{1}{\textcolor{red}{0}} [c_{ij}]'$$

→ Em geral, o computo da inversa **não é simples**.

→ A inversa de uma matriz triangular também é triangular.

→ No caso das matrizes triangulares, é mais fácil calcular a inversa resolvendo $AA^{-1} = I$.

→ No MATLAB, podemos calcular a inversa utilizando o comando `inv`.



Equações Algébricas Lineares

Com as novas definições, apresentamos o Teorema 3.3, que trata do caso $Ax = y$ em que A é quadrada.

Teorema 3.3

Considere $Ax = y$ em que A é quadrada.

- 1. Se A for não singular, então a equação possui uma única solução para todo y , e esta é igual a $A^{-1}y$. Particularmente, se $y = \mathbf{0}$, a única solução é $x = \mathbf{0}$.*
- 2. A equação homogênea $Ax = \mathbf{0}$ não apresenta solução se e somente se A for não singular. O número de soluções LI é igual à nulidade de A .*



Equações Algébricas Lineares

Vamos destrinchar o enunciado do Teorema 3.3:

→ Se a matriz $n \times n$ A for **não singular**, então a nulidade de A será 0, pois;

↗ Tem posto completo

$$\text{nullity}(A) = n - \text{rank}(A) = n - n = 0$$

→ Logo, só existe uma **única solução** para $Ax = y$.

→ E, multiplicando esta equação por A^{-1} **pela esquerda**, temos:

$$A^{-1}Ax = A^{-1}y \Rightarrow x = A^{-1}y,$$

que é a única solução.



Equações Algébricas Lineares

Vamos destrinchar o enunciado do Teorema 3.3:

→ Ainda, como a **nulidade de A é 0** se A for não singular, então isso significa que **não existem vetores nulos de A** . Logo, não existe x tal que

$$Ax = 0$$

→ Se $nullity(A) = p$, então existem p vetores nulos LI $\{n_1, n_2, \dots, n_p\}$ que podem ser combinados linearmente para formar as infinitas soluções de $Ax = 0$.

Teoria de Sistemas Lineares

Transformação de Similaridade



Transformação de Similaridade

Exemplo 6. Considere a matriz

$$A = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix} =: [\mathbf{a}_1 \quad \mathbf{a}_2 \quad \mathbf{a}_3]$$

Observe que cada coluna $\mathbf{a}_i$ de A é uma **representação** do vetor $A\mathbf{i}_i$ com respeito a base ortonormal $\{\mathbf{i}_1, \mathbf{i}_2, \mathbf{i}_3\}$.



Transformação de Similaridade

Exemplo 6.

De fato, tomando a terceira coluna de A , por exemplo:

$$A\mathbf{i}_3 = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} \leftarrow \text{vetor } A\mathbf{i}_3$$

Com respeito a base ortonormal $\{\mathbf{i}_1, \mathbf{i}_2, \mathbf{i}_3\}$:

$$A\mathbf{i}_3 = Q\bar{\mathbf{x}}_3 = [\mathbf{i}_1 \quad \mathbf{i}_2 \quad \mathbf{i}_3] \bar{\mathbf{x}}_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

i.e., $\mathbf{a}_3$ é a representação ($\bar{\mathbf{x}}_3$) de $A\mathbf{i}_3$ na base ortonormal $\{\mathbf{i}_1, \mathbf{i}_2, \mathbf{i}_3\}$.



Transformação de Similaridade

Exemplo 6. De forma análoga,

$$Ai_1 = Q\bar{x}_1 = [i_1 \ i_2 \ i_3]\bar{x}_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 3 \\ -2 \\ 4 \end{bmatrix} = \begin{bmatrix} 3 \\ -2 \\ 4 \end{bmatrix}$$

$$Ai_2 = Q\bar{x}_2 = [i_1 \ i_2 \ i_3]\bar{x}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}$$

Resumindo: As colunas a_1, a_2 e a_3 da matriz A são as **representações** dos vetores Ai_1, Ai_2 e Ai_3 com respeito à base ortonormal $\{i_1, i_2, i_3\}$.

Ou, em outras palavras, a representação de A na base ortonormal é ela mesma.



Transformação de Similaridade

Exemplo 6. Agora, seja $b = [0 \ 0 \ 1]'$. Então, considerando a matriz A :

$$Ab = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix},$$

$$A(Ab) = A^2b = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix} \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} -4 \\ 2 \\ -3 \end{bmatrix},$$

$$A(A^2b) = A^3b = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix} \begin{bmatrix} -4 \\ 2 \\ -3 \end{bmatrix} = \begin{bmatrix} -5 \\ 10 \\ -13 \end{bmatrix}$$

Note que $\{Ab, A^2b, A^3b\}$ são LI, e portanto, formam uma base em $\mathcal{R}^3$.

De fato, é possível verificar que $A^3b = 17b - 15Ab + 5A^2b$.



Transformação de Similaridade

Exemplo 6.

Como $\{\mathbf{b}, A\mathbf{b}, A^2\mathbf{b}\}$ são LI, e portanto, formam uma base em $\mathcal{R}^3$, podemos buscar encontrar a representação de

$$A = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix}$$

com respeito a nova base $\{\mathbf{b}, A\mathbf{b}, A^2\mathbf{b}\}$ que criamos.

Assim, a matriz

$$\bar{A} = [\bar{a}_1 \quad \bar{a}_2 \quad \bar{a}_3]$$

é a representação a ser encontrada.



Transformação de Similaridade

Exemplo 6. Como vimos para a base **ortonormal**, se multiplicarmos A por cada vetor da base $(A\mathbf{i}_1, A\mathbf{i}_2, A\mathbf{i}_3)$, encontraremos a representação correspondente. Então, para a nova base $\{\mathbf{b}, A\mathbf{b}, A^2\mathbf{b}\}$ fazemos:

$$A\mathbf{i}_1 = Q\mathbf{a}_1 = [\mathbf{i}_1 \quad \mathbf{i}_2 \quad \mathbf{i}_3] \begin{bmatrix} 3 \\ -2 \\ 4 \end{bmatrix}$$

$$A\mathbf{b} = \bar{Q}\bar{\mathbf{a}}_1 = [b \quad Ab \quad A^2b] \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$A\mathbf{i}_2 = Q\mathbf{a}_2 = [\mathbf{i}_1 \quad \mathbf{i}_2 \quad \mathbf{i}_3] \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}$$

$$AA\mathbf{b} = \bar{Q}\bar{\mathbf{a}}_2 = [b \quad Ab \quad A^2b] \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

$$A\mathbf{i}_3 = Q\mathbf{a}_3 = [\mathbf{i}_1 \quad \mathbf{i}_2 \quad \mathbf{i}_3] \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

$$AA^2\mathbf{b} = \bar{Q}\bar{\mathbf{a}}_3 = [b \quad Ab \quad A^2b] \begin{bmatrix} 17 \\ -15 \\ 5 \end{bmatrix}^*$$

* Lembrando que $AA^2b = A^3b = 17b - 15Ab + 5A^2b$.



Transformação de Similaridade

Exemplo 6. Assim, a representação da matriz

$$A = [a_1 \ a_2 \ a_3] = \begin{bmatrix} 3 & 2 & -1 \\ -2 & 1 & 0 \\ 4 & 3 & 1 \end{bmatrix}$$

com respeito a base $\{b, Ab, A^2b\}$, onde $b = [0 \ 0 \ 1]'$ é

$$\bar{A} = [\bar{a}_1 \ \bar{a}_2 \ \bar{a}_3] = \begin{bmatrix} 1 & 0 & 17 \\ 0 & 1 & -15 \\ 0 & 0 & 5 \end{bmatrix}$$



Transformação de Similaridade

De forma geral, se A é uma matriz $n \times n$, então se existir um vetor $\mathbf{b}$ $n \times 1$ tal que os vetores $\mathbf{b}, A\mathbf{b}, A^2\mathbf{b}$ e $A^{n-1}\mathbf{b}$ sejam LI, e se

$$A^n \mathbf{b} = \beta_1 \mathbf{b} + \beta_2 A\mathbf{b} + \beta_3 A^2\mathbf{b} + \cdots + \beta_n A^{n-1}\mathbf{b}$$

então, a representação de A com respeito à base $\{\mathbf{b}, A\mathbf{b}, A^2\mathbf{b}, \dots, A^{n-1}\mathbf{b}\}$ é

$$\bar{A} = \begin{bmatrix} 0 & 0 & \cdots & \beta_1 \\ 1 & 0 & \cdots & \beta_2 \\ 0 & 1 & \cdots & \beta_3 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 1 & \beta_n \end{bmatrix}$$

Esta matriz é dita estar na **forma companheira**.



Transformação de Similaridade

Formalizando esta ideia, se $Ax = y$, temos que a matriz A *mapeia* $x \in \mathcal{R}^n$ em $y \in \mathcal{R}^n$ (i.e., a matriz A , aplicada a x , produz um vetor y).

Considerando a base $\{q_1, q_2, \dots, q_n\}$, a equação se torna

$$\bar{A}\bar{x} = \bar{y}$$

Onde $\bar{A}$, $\bar{x}$ e $\bar{y}$ são as representações de A , x e y com respeito a base $\{q_1, q_2, \dots, q_n\}$.



Transformação de Similaridade

Como vimos, isso equivale dizer

$$\mathbf{x} = \mathbf{Q}\bar{\mathbf{x}} \quad \text{e} \quad \mathbf{y} = \mathbf{Q}\bar{\mathbf{y}}$$

onde $\mathbf{Q} = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_n]$ é uma matriz não singular.

Portanto, a partir de $\mathbf{A}\mathbf{x} = \mathbf{y}$ e $\bar{\mathbf{A}}\bar{\mathbf{x}} = \bar{\mathbf{y}}$, teremos:

$$\mathbf{A}\mathbf{Q}\bar{\mathbf{x}} = \mathbf{Q}\bar{\mathbf{y}} \quad \text{ou} \quad \bar{\mathbf{y}} = \mathbf{Q}^{-1}\mathbf{A}\mathbf{Q}\bar{\mathbf{x}}$$

O que implica

$$\bar{\mathbf{A}} = \mathbf{Q}^{-1}\mathbf{A}\mathbf{Q} \quad \text{ou} \quad \mathbf{A} = \mathbf{Q}\bar{\mathbf{A}}\mathbf{Q}^{-1}$$



Transformação de Similaridade

A relação

$$\bar{A} = Q^{-1}AQ \text{ ou } A = Q\bar{A}Q^{-1}$$

é chamada de **Transformação de Similaridade** e dizemos que A e $\bar{A}$ são *similares*.

A transformação de Similaridade também pode ser escrita como

$$AQ = Q\bar{A}$$

ou

$$A[q_1 \ q_2 \ \cdots \ q_n] = [Aq_1 \ Aq_2 \ \cdots \ Aq_n] = [q_1 \ q_2 \ \cdots \ q_n]\bar{A}$$



Transformação de Similaridade

Veja que

$$AQ = Q\bar{A}$$

ou

$$A[q_1 \ q_2 \ \cdots \ q_n] = [Aq_1 \ Aq_2 \ \cdots \ Aq_n] = [q_1 \ q_2 \ \cdots \ q_n]\bar{A}$$

implica que cada coluna de $\bar{A}$ é a **representação** de Aq_i na base $\{q_1, q_2, \dots, q_n\}$, como já tínhamos observado no exemplo numérico anterior. Veja:

$$\begin{aligned} [Aq_1 \ Aq_2 \ \cdots \ Aq_n] &= [q_1 \ q_2 \ \cdots \ q_n]\bar{A} \\ &= Q[\bar{a}_1 \ \bar{a}_2 \ \cdots \ \bar{a}_n] = [Q\bar{a}_1 \ Q\bar{a}_2 \ \cdots \ Q\bar{a}_n] \end{aligned}$$

Isto é: $Aq_1 = Q\bar{a}_1$, $Aq_2 = Q\bar{a}_2$, $\dots$, $Aq_n = Q\bar{a}_n$.

Teoria de Sistemas Lineares

Forma Diagonal e
Forma de Jordan



Autovalores

Como vimos, uma dada matriz A possui diferentes representações com respeito a diferentes conjuntos de bases. Estudaremos uma importante representação de matrizes: **forma diagonal ou bloco-diagonal**.

Essa representação especial passa pela definição de **autovalores**.

Um escalar λ é um **autovalor** de uma matriz quadrada A $n \times n$ se existir um vetor x $n \times 1$, não nulo, tal que

$$Ax = \lambda x$$

Qualquer vetor não nulo x que satisfaça esta igualdade é chamado de **autovetor** de A associado ao autovalor λ .



Autovalores

Podemos determinar os autovalores de A fazendo:

$$A\mathbf{x} = \lambda\mathbf{x} = \lambda\mathbf{I}_n\mathbf{x} \Rightarrow$$

$$(A - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$$

Como vimos, se $A - \lambda\mathbf{I}_n$ é não singular*, então a única solução é $\mathbf{x} = \mathbf{0}$.

Logo, para que exista uma solução não nula, é necessário que $A - \lambda\mathbf{I}_n$ seja singular, ou

$$\det(A - \lambda\mathbf{I}_n) = 0$$

*E, portanto, tem posto de colunas completo, implicando em nulidade igual a 0.



Autovalores

Definimos

$$\Delta(\lambda) = \det(\lambda \mathbf{I}_n - \mathbf{A})$$

que é um polinômio mônico* de grau n com coeficientes reais, chamado de **polinômio característico**.

Se λ é uma raiz de $\Delta(\lambda)$ então $\det(\mathbf{A} - \lambda \mathbf{I}_n) = 0$ e, portanto, a equação $(\mathbf{A} - \lambda \mathbf{I}_n)\mathbf{x} = \mathbf{0}$ tem ao menos uma solução $\mathbf{x} \neq \mathbf{0}$.

Assim, **toda raiz de $\Delta(\lambda)$ é um autovalor de $\mathbf{A}$** . E, como $\Delta(\lambda)$ tem grau n , a matriz $\mathbf{A}$ $n \times n$ terá n autovalores (não necessariamente distintos).

*apresenta coeficiente do termo de maior grau (coeficiente líder) igual a 1.



Autovalores

Matrizes nas **formas companheiras**

$$\begin{bmatrix} 0 & 0 & 0 & -\alpha_4 \\ 1 & 0 & 0 & -\alpha_3 \\ 0 & 1 & 0 & -\alpha_2 \\ 0 & 0 & 1 & -\alpha_1 \end{bmatrix} \quad \text{e} \quad \begin{bmatrix} -\alpha_1 & -\alpha_2 & -\alpha_3 & -\alpha_4 \\ 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

e suas transpostas

$$\begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ -\alpha_1 & -\alpha_2 & -\alpha_3 & -\alpha_4 \end{bmatrix} \quad \text{e} \quad \begin{bmatrix} -\alpha_1 & 1 & 0 & 0 \\ -\alpha_2 & 0 & 1 & 0 \\ -\alpha_3 & 0 & 0 & 1 \\ -\alpha_4 & 0 & 0 & 0 \end{bmatrix}$$

apresentam o seguinte polinômio característico:

$$\Delta(\lambda) = \lambda^4 + \alpha_1 \lambda^3 + \alpha_2 \lambda^2 + \alpha_3 \lambda + \alpha_4$$

podendo ser facilmente formadas a partir dos coeficientes de $\Delta(\lambda)$.



Forma Diagonal

→ Caso 01: Autovalores *distintos*

Se λ_i , $i = 1, 2, \dots, n$, forem os autovalores de A e forem todos distintos:

$$\hat{A} = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Em que $\hat{A}$ é a representação de A com respeito a base $\{\mathbf{q}_1, \dots, \mathbf{q}_n\}$, onde $\mathbf{q}_i$ é o autovetor associado a λ_i .



Forma Diagonal

Isso ocorre pois para cada autovalor λ_i existe um autovetor $\mathbf{q}_i$.

É possível provar que o conjunto dos autovetores $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$ é LI. Portanto, estes podem ser usados para formar uma base.

Veja que se definirmos $\mathbf{Q} = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n]$ então

$$\mathbf{A}\mathbf{q}_1 = \lambda_1\mathbf{q}_1 \Rightarrow \mathbf{A}\mathbf{q}_1 = \mathbf{Q}\bar{\mathbf{a}}_1 = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n] \begin{bmatrix} \lambda_1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$



Forma Diagonal

Sucessivamente:

$$\begin{aligned}
 A\mathbf{q}_2 = \lambda_2\mathbf{q}_2 \Rightarrow A\mathbf{q}_2 = Q\bar{\mathbf{a}}_2 &= [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n] \begin{bmatrix} 0 \\ \lambda_2 \\ \vdots \\ 0 \end{bmatrix} \\
 &\vdots \\
 A\mathbf{q}_n = \lambda_n\mathbf{q}_n \Rightarrow A\mathbf{q}_n = Q\bar{\mathbf{a}}_n &= [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n] \begin{bmatrix} 0 \\ 0 \\ \vdots \\ \lambda_n \end{bmatrix}
 \end{aligned}$$



Forma Diagonal

Assim, a representação $\hat{A}$ de A com respeito a base $\{\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n\}$ é

$$\hat{A} = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

Assim, toda matriz com **autovalores distintos** tem uma **representação diagonal** utilizando seus autovetores como base, obtida fazendo

$$\hat{A} = Q^{-1}AQ$$



Forma Diagonal

Exemplo 7. Seja $A = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 2 \\ 0 & 1 & 1 \end{bmatrix}$.

Então, seu polinômio característico é

$$\begin{aligned} \Delta(\lambda) &= \det(\lambda I - A) = \det \begin{bmatrix} \lambda & 0 & 0 \\ -1 & \lambda & -2 \\ 0 & -1 & \lambda - 1 \end{bmatrix} \\ \Delta(\lambda) &= \lambda^2(\lambda - 1) - 2\lambda = \lambda[\lambda(\lambda - 1) - 2] = \lambda(\lambda^2 - \lambda - 2) \end{aligned}$$

E, suas raízes são $\lambda_1 = 2$, $\lambda_2 = -1$ e $\lambda_3 = 0$.



Forma Diagonal

Exemplo 7.

Assim, o autovetor associado ao autovalor $\lambda_1 = 2$ é qualquer solução não nula para

$$A\mathbf{q}_1 = \lambda_1\mathbf{q}_1 \Rightarrow (A - 2I)\mathbf{q}_1 = \begin{bmatrix} -2 & 0 & 0 \\ 1 & -2 & 2 \\ 0 & 1 & -1 \end{bmatrix} \mathbf{q}_1 = \mathbf{0}$$

Por exemplo, $\mathbf{q}_1 = [0 \ 1 \ 1]'$ é um autovetor associado a $\lambda = 2$.



Forma Diagonal

Exemplo 7.

Já o autovetor associado ao autovalor $\lambda_2 = -1$ é qualquer solução não nula para

$$A\mathbf{q}_2 = \lambda_2\mathbf{q}_2 \Rightarrow (A - (-1)I)\mathbf{q}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 2 \\ 0 & 1 & 2 \end{bmatrix} \mathbf{q}_2 = \mathbf{0}$$

Por exemplo, $\mathbf{q}_2 = [0 \ -2 \ 1]'$ é um autovetor associado a $\lambda = -1$.



Forma Diagonal

Exemplo 7.

E o autovetor associado ao autovalor $\lambda_3 = 0$ é qualquer solução não nula para

$$A\mathbf{q}_3 = \lambda_3\mathbf{q}_3 \Rightarrow (A - (0)I)\mathbf{q}_3 = \begin{bmatrix} 0 & 0 & 0 \\ 1 & 0 & 2 \\ 0 & 1 & 1 \end{bmatrix} \mathbf{q}_3 = \mathbf{0}$$

Por exemplo, $\mathbf{q}_3 = [2 \ 1 \ -1]'$ é um autovetor associado a $\lambda = 0$.



Forma Diagonal

Exemplo 7.

Desta forma, a representação de A com respeito a base $\{\mathbf{q}_1, \mathbf{q}_2, \mathbf{q}_3\}$ é:

$$\hat{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Que também pode ser obtida fazendo

$$\hat{A} = Q^{-1}AQ$$

embora não seja tão simples, por conta da inversa de $Q = [\mathbf{q}_1 \ \mathbf{q}_2 \ \mathbf{q}_3]$.




Forma Diagonal

Exemplo 8. Seja $A = \begin{bmatrix} -1 & 1 & 1 \\ 0 & 4 & -13 \\ 0 & 1 & 0 \end{bmatrix}$.

Então, seu polinômio característico é

$$\begin{aligned}\Delta(\lambda) &= \det(\lambda I - A) = \det \begin{bmatrix} \lambda + 1 & 1 & 1 \\ 0 & \lambda - 4 & -13 \\ 0 & 1 & \lambda \end{bmatrix} \\ \Delta(\lambda) &= (\lambda + 1)(\lambda - 4)\lambda + 13(\lambda + 1) = (\lambda + 1)[(\lambda - 4)\lambda + 13] \\ \Delta(\lambda) &= (\lambda + 1)(\lambda^2 - 4\lambda + 13)\end{aligned}$$

E, suas raízes são $\lambda_1 = -1$, $\lambda_2 = 2 + j3$ e $\lambda_3 = 2 - j3$.



Forma Diagonal

Exemplo 8. Portanto, neste caso, a matriz A possui autovalores complexos. Entretanto, como são distintos, a representação de A com respeito a base $\{q_1, q_2, q_3\}$ será

$$\hat{A} = \begin{bmatrix} -1 & 0 & 0 \\ 0 & 2 + j3 & 0 \\ 0 & 0 & 2 - j3 \end{bmatrix}$$

Sendo os autovetores as soluções não nulas para $(A - \lambda_1 I)q_1 = 0$, $(A - \lambda_2 I)q_2 = 0$ e $(A - \lambda_3 I)q_3 = 0$. Temos, por exemplo:

$$Q = [q_1 \quad q_2 \quad q_3] = \begin{bmatrix} 1 & j & -j \\ 0 & -3 + j2 & -3 - j2 \\ 0 & j & -j \end{bmatrix}$$

Complexo conjugado



Autovetor Generalizado

→ Caso 02: Autovalores *repetidos*

Considere que a matriz A $n \times n$ tem um autovalor λ com multiplicidade n . Ou seja, os n autovalores de A são $\{\lambda, \lambda, \dots, \lambda, \lambda\}$ (todos iguais).

Para exemplificar, vamos assumir que $n = 4$. E também suponhamos que $(A - \lambda I)$ tenha posto 3 e, portanto, a nulidade é 1.

Assim, a equação $(A - \lambda I)\mathbf{q} = \mathbf{0}$ tem apenas uma solução LI.

Ou seja, A só possui um autovetor associado a λ .



Autovetor Generalizado

→ Caso 02: Autovalores *repetidos*

Para construir uma representação de A em termos de seus autovetores precisamos de mais 3 vetores LI (lembrando que $A \in \mathcal{R}^{4 \times 4}$).

Escolheremos q_2 , q_3 e q_4 tendo as seguintes propriedades:

- $(A - \lambda I)^2 q_2 = 0$
- $(A - \lambda I)^3 q_3 = 0$
- $(A - \lambda I)^4 q_4 = 0$



Autovetor Generalizado

Chamaremos v de **autovetor generalizado de grau n** se

$$(A - \lambda I)^n v = 0 \quad e \quad (A - \lambda I)^{n-1} v \neq 0$$

Perceba que se $n = 1$, então

$$(A - \lambda I)^1 v = 0 \quad e \quad (A - \lambda I)^0 v \neq 0 \Rightarrow$$

$$(A - \lambda I)v = 0 \quad e \quad v \neq 0$$

(definição de autovetor comum)



Autovetor Generalizado

No caso de $n = 4$, se existe um v tal que $(A - \lambda I)^4 v = 0$, definimos:

$$v_4 := v$$

Logo, podemos escrever

$$\begin{aligned} (A - \lambda I)^4 v_4 &= 0 \Rightarrow \\ (A - \lambda I)^3 (A - \lambda I) v_4 &= 0 \end{aligned}$$

A partir disto, definimos um **segundo** vetor:

$$v_3 := (A - \lambda I) v_4 = (A - \lambda I) v$$

→ Veja que isso resulta $(A - \lambda I)^3 v_3 = 0$.



Autovetor Generalizado

Seguindo o raciocínio, se $(A - \lambda I)^3 \mathbf{v}_3 = 0$, então

$$(A - \lambda I)^2 (A - \lambda I) \mathbf{v}_3 = \mathbf{0}$$

E, a partir disto, definimos um **terceiro** vetor:

$$\begin{aligned} \mathbf{v}_2 &:= (A - \lambda I) \mathbf{v}_3 \\ &= (A - \lambda I)(A - \lambda I) \mathbf{v}_4 = (A - \lambda I)^2 \mathbf{v} \end{aligned}$$

→ Note que isso implica $(A - \lambda I)^2 \mathbf{v}_2 = 0$.



Autovetor Generalizado

Por fim, se $(A - \lambda I)v_2 = 0$, então

$$(A - \lambda I)(A - \lambda I)v_2 = 0$$

A partir da qual definimos um **quarto** vetor:

$$\begin{aligned} v_1 &:= (A - \lambda I)v_2 \\ &= (A - \lambda I)(A - \lambda I)^2 v_4 = (A - \lambda I)^3 v \end{aligned}$$

→ Note que isso implica $(A - \lambda I)^3 v_1 = 0$.



Autovetor Generalizado

Resumindo, definimos uma **cadeia de autovetores generalizados** de comprimento $n = 4$:

$$\begin{aligned}v_4 &:= v \\v_3 &:= (A - \lambda I)v_4 = (A - \lambda I)v \\v_2 &:= (A - \lambda I)v_3 = (A - \lambda I)^2 v \\v_1 &:= (A - \lambda I)v_2 = (A - \lambda I)^3 v\end{aligned}$$

que possuem as propriedades:

$$(A - \lambda I)^4 v_4 = \mathbf{0}, (A - \lambda I)^3 v_3 = \mathbf{0}, (A - \lambda I)^2 v_2 = \mathbf{0} \text{ e } (A - \lambda I)v_1 = \mathbf{0}$$



Forma de Jordan

Da maneira com que são gerados, os vetores $\mathbf{v}_1$, $\mathbf{v}_2$, $\mathbf{v}_3$ e $\mathbf{v}_4$ são LI. Logo, formam uma base para $\mathcal{R}^4$.

Ainda, das definições, segue que:

$$\begin{aligned}(A - \lambda I)\mathbf{v}_1 &= \mathbf{0} \Rightarrow A\mathbf{v}_1 = \lambda\mathbf{v}_1 \\ \mathbf{v}_1 &:= (A - \lambda I)\mathbf{v}_2 \Rightarrow A\mathbf{v}_2 = \mathbf{v}_1 + \lambda\mathbf{v}_2 \\ \mathbf{v}_2 &:= (A - \lambda I)\mathbf{v}_3 \Rightarrow A\mathbf{v}_3 = \mathbf{v}_2 + \lambda\mathbf{v}_3 \\ \mathbf{v}_3 &:= (A - \lambda I)\mathbf{v}_4 \Rightarrow A\mathbf{v}_4 = \mathbf{v}_3 + \lambda\mathbf{v}_4\end{aligned}$$



Forma de Jordan

Consequentemente, se $Q = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3 \ \mathbf{v}_4]$, então teremos as **representações**:

$$A\mathbf{v}_1 = \lambda\mathbf{v}_1 \Rightarrow A\mathbf{v}_1 = Q\bar{\mathbf{v}}_1 = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3 \ \mathbf{v}_4] \begin{bmatrix} \lambda \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

$$A\mathbf{v}_2 = \mathbf{v}_1 + \lambda\mathbf{v}_2 \Rightarrow A\mathbf{v}_2 = Q\bar{\mathbf{v}}_2 = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3 \ \mathbf{v}_4] \begin{bmatrix} 1 \\ \lambda \\ 0 \\ 0 \end{bmatrix}$$



Forma de Jordan

e

$$A\mathbf{v}_3 = \mathbf{v}_2 + \lambda\mathbf{v}_3 \Rightarrow A\mathbf{v}_3 = Q\bar{\mathbf{v}}_3 = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3 \ \mathbf{v}_4] \begin{bmatrix} 0 \\ 1 \\ \lambda \\ 0 \end{bmatrix}$$

$$A\mathbf{v}_4 = \mathbf{v}_3 + \lambda\mathbf{v}_4 \Rightarrow A\mathbf{v}_4 = Q\bar{\mathbf{v}}_4 = [\mathbf{v}_1 \ \mathbf{v}_2 \ \mathbf{v}_3 \ \mathbf{v}_4] \begin{bmatrix} 0 \\ 0 \\ 1 \\ \lambda \end{bmatrix}$$



Forma de Jordan

Assim, a representação da matriz A com respeito à base $\{v_1, v_2, v_3, v_4\}$ é:

$$J := \begin{bmatrix} \lambda & 1 & 0 & 0 \\ 0 & \lambda & 1 & 0 \\ 0 & 0 & \lambda & 1 \\ 0 & 0 & 0 & \lambda \end{bmatrix}$$

Esta matriz, chamada de **bloco de Jordan** de ordem $n = 4$.

Veja que J apresenta os **autovalores repetidos** na **diagonal principal** e **1's** na **superdiagonal**.



Forma de Jordan

Vejam os agora o caso em que $(A - \lambda I)$ tem posto n , e portanto, **nulidade 2**, indicando que A possui **dois autovetores LI**, e são necessários mais $(n - 2)$ autovetores para formar a base em $\mathcal{R}^n$.

Neste caso, serão construídas **duas** cadeias de autovetores generalizados, uma a partir de cada autovetor LI:

Cadeia 1: $v_1, v_2, \dots, v_k$

Cadeia 2: $u_1, u_2, \dots, u_l$

De modo que $k + l = n$.



Forma de Jordan

Em conjunto, os vetores $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k, \mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_l\}$ são LI, e podem formar uma base em $\mathcal{R}^n$.

E, com respeito a esta base, a matriz A terá representação na forma

$$\hat{A} = \text{diag}\{J_1, J_2\}$$

onde J_1 e J_2 são **blocos de Jordan** de ordem k e l , respectivamente.



Forma de Jordan

No caso particular de uma matriz A de dimensão 5×5 com um autovalor λ_1 de multiplicidade 4 e um autovalor simples λ_2 , existirá uma matriz não singular Q tal que $\hat{A} = Q^{-1}AQ$ assumirá uma das formas abaixo:

$$\hat{A}_1 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_2 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_3 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_4 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_5 = \begin{bmatrix} \lambda_1 & 0 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$



Forma de Jordan

No **primeiro** caso ($\hat{A}_1$) a **nulidade de $(A - \lambda_1 I)$ é 1**, então existe apenas um autovetor LI, e 3 vetores são construídos em uma cadeia de autovetores generalizados, resultando em **um bloco de Jordan**.

$$\hat{A}_1 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

J_1

Assim, forma-se uma representação bloco-diagonal, composta por λ_2 e um **bloco de Jordan de ordem 4 (J_1)**.



Forma de Jordan

No **segundo** caso ($\hat{A}_2$ e $\hat{A}_3$) a **nulidade de $(A - \lambda_1 I)$ é 2**, então existem dois autovetor LI, e 2 vetores são construídos a partir de duas cadeias de autovetores generalizados, resultando em **dois blocos de Jordan**.

$$\hat{A}_2 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

The matrix is annotated with two Jordan blocks: J_1 (a 3x3 block with λ_1 on the diagonal and 1s on the super-diagonal) and J_2 (a 2x2 block with λ_1 and λ_2 on the diagonal). Arrows point from the labels J_1 and J_2 to their respective blocks in the matrix.

Poderão existir, assim:

- **Um bloco** de Jordan de ordem 3 (J_1) e **um bloco** de Jordan de ordem 1 (J_2).



Forma de Jordan

No **segundo** caso ($\hat{A}_2$ e $\hat{A}_3$) a **nulidade de $(A - \lambda_1 I)$ é 2**, então existem dois autovetor LI, e 2 vetores são construídos a partir de duas cadeias de autovetores generalizados, resultando em **dois blocos de Jordan**.

$$\hat{A}_3 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

Diagram illustrating the Jordan form $\hat{A}_3$. The matrix is partitioned into two Jordan blocks, J_1 and J_2 , each of order 2. J_1 is highlighted in the top-left 2x2 submatrix (rows 1-2, columns 1-2) and J_2 is highlighted in the bottom-left 2x2 submatrix (rows 3-4, columns 3-4). Both blocks have diagonal entries λ_1 and a super-diagonal entry 1. The bottom-right entry is λ_2 .

Poderão existir, assim:

- **Dois** blocos de Jordan de ordem 2 (J_1 e J_2).



Forma de Jordan

No **terceiro** caso ($\hat{A}_4$) a **nulidade de $(A - \lambda_1 I)$ é 3**, então existem três autovetores LI, e 1 vetor é construído a partir de 3 cadeias de autovetores generalizados, resultando em **três blocos de Jordan**.

$$\hat{A}_4 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

Diagram illustrating the Jordan blocks J_1 , J_2 , and J_3 within the matrix $\hat{A}_4$. J_1 is a 2x2 block with λ_1 on the diagonal and 1 on the super-diagonal. J_2 is a 1x1 block with λ_1 . J_3 is a 1x1 block with λ_2 .

Neste caso, serão formados um bloco de Jordan de ordem 2 (J_1), e dois blocos de Jordan de ordem 1 (J_2 e J_3).



Forma de Jordan

No **quarto** caso ($\hat{A}_5$) a **nulidade de $(A - \lambda_1 I)$ é 4**, então existem quatro autovetores LI, e assim teremos **quatro blocos de Jordan** de ordem 1.

$$\hat{A}_5 = \begin{bmatrix} \lambda_1 & 0 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

Diagram illustrating the Jordan form $\hat{A}_5$ with four Jordan blocks of order 1, labeled J_1, J_2, J_3, J_4 , each corresponding to a diagonal element λ_1 (except for the last element λ_2).



Forma de Jordan

Todas essas matrizes são **triangulares** e **bloco-diagonais**, com blocos de Jordan na diagonal, e são chamadas de representação na **forma de Jordan**.

$$\hat{A}_1 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_2 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 1 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_3 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 1 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_4 = \begin{bmatrix} \lambda_1 & 1 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$

$$\hat{A}_5 = \begin{bmatrix} \lambda_1 & 0 & 0 & 0 & 0 \\ 0 & \lambda_1 & 0 & 0 & 0 \\ 0 & 0 & \lambda_1 & 0 & 0 \\ 0 & 0 & 0 & \lambda_1 & 0 \\ 0 & 0 & 0 & 0 & \lambda_2 \end{bmatrix}$$



Forma de Jordan

As formas de Jordan podem ser utilizadas para gerarem muitas propriedades gerais de matrizes.

Por exemplo, uma vez que $\det(\mathbf{CD}) = \det \mathbf{C} \det \mathbf{D}$ e $\det \mathbf{Q} \det \mathbf{Q}^{-1} = \det \mathbf{I} = 1$, então

$$\det \mathbf{A} = \det \mathbf{Q} \det \hat{\mathbf{A}} \det \mathbf{Q}^{-1} = \det \hat{\mathbf{A}}$$

→ Isso implica em $\det \mathbf{A} = \prod \lambda_i$

(o determinante de $\mathbf{A}$ é igual ao produto de todos autovalores de $\mathbf{A}$)

→ Portanto, $\mathbf{A}$ é **não singular** ($\det \mathbf{A} \neq 0$) **apenas se não possuir autovalores nulos.**



Forma de Jordan

Outra propriedade importante dos blocos de Jordan são os **nilpotentes**.

Para o caso de um bloco de Jordan de ordem 4, teremos:

$$(J - \lambda I) = \begin{bmatrix} \lambda & 1 & 0 & 0 \\ 0 & \lambda & 1 & 0 \\ 0 & 0 & \lambda & 1 \\ 0 & 0 & 0 & \lambda \end{bmatrix} - \begin{bmatrix} \lambda & 0 & 0 & 0 \\ 0 & \lambda & 0 & 0 \\ 0 & 0 & \lambda & 0 \\ 0 & 0 & 0 & \lambda \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Dizemos que a matriz $(J - \lambda I)$ é nilpotente pois existe um $k > 0$ tal que $(J - \lambda I)^k = \mathbf{0}$



Forma de Jordan

De fato:

$$(J - \lambda I)^2 = \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$(J - \lambda I)^3 = \begin{bmatrix} 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

e $(J - \lambda I)^k = \mathbf{0}$, para todo $k \geq 4$.

Bibliografia

Materiais Consultados/Utilizados

CHEN, Chi-Tsong. **Linear system theory and design**. 3 ed. New York, NY: Oxford University Press, 1999, 350 p. ISBN 0-19-511777-8

LATHI, Bhagwandas Pannalal. **Principles of linear systems and signals**. Oxford University Press, 2017.