




Teoria e Aplicações de Inteligência Computacional I

Aula I – Plano de Ensino e Introdução a disciplina

Fundamentos da Inteligência Computacional

Prof. Dr. Guilherme Augusto Defalque

Mestrado em Engenharia Elétrica - PPGEE - UFMS

Conceitos, paradigmas, redes neurais, séries temporais aplicações em Engenharia Elétrica.

Prof. Dr. Guilherme Augusto Defalque

Formação Acadêmica

Doutorado em Ciência da Computação – UFMS (2020 – 2024)

Sistemas Distribuídos com ênfase em Sistemas: IoT (IA e Sistemas Embarcados); Ciência de Dados voltada à análise de dados Geoespaciais e Agricultura de Precisão. Desenvolvimento de Modelos de Aprendizado de Máquina aplicados a DSS.

Mestrado em Ciência da Computação – UFMS (2017 – 2019)

Ênfase em Computação Aplicada em Sistemas Pervasivos: IoT. Wearables (dispositivos vestíveis) para pecuária de precisão. Sistemas embarcados com ênfase em transdutores de sons.

Bacharelado em Engenharia de Computação – UFMS (2011 – 2016)

Ênfase em microcontroladores aplicados ao estudo de sensores de água e solo.

MBA em Geotecnologias e Análise de Dados Espaciais – AMBGEO / Anhanguera (2024 – 2026)

Certificação em parceria com a Faculdade Anhanguera.

Experiência Internacional

Pesquisador no INESC TEC – Universidade do Porto, Portugal (2023)

Pesquisa em sistemas distribuídos e aprendizado de máquina em ambiente internacional.

Prof. Dr. Guilherme Augusto Defalque

Interesses de Pesquisa



Sistemas Embarcados & IoT

Computação Distribuída e dispositivos conectados.



Deep Learning & Machine Learning

Aprendizado Supervisionado e Não Supervisionado aplicados a DSS.



Ciência de Dados & Geoprocessamento

Análise de dados geoespaciais, Agricultura e Pecuária de Precisão.



Redes de Computadores & Computação Distribuída

Arquiteturas distribuídas e protocolos de rede.



Engenharia de Prompt

Otimização de interações com modelos de linguagem de grande escala (LLMs).

Plano de Ensino

Objetivos da Disciplina

Apresentar os fundamentos teóricos e práticos da Inteligência Computacional aplicados à modelagem e previsão de séries temporais, explorando técnicas estatísticas clássicas, modelos híbridos e redes neurais profundas para resolução de problemas de engenharia elétrica.

Plano de Ensino

Metodologia

A disciplina será desenvolvida por meio de:

- Aulas expositivas dialogadas
- Estudos dirigidos e resolução de problemas
- Análise de artigos científicos
- Atividades práticas utilizando Python

Os estudantes desenvolverão estudos de caso utilizando conjuntos de dados reais, contemplando todas as etapas do processo de modelagem, desde o pré-processamento até a avaliação comparativa dos modelos. Serão incentivadas discussões críticas sobre a escolha dos modelos, interpretação dos resultados e limitações das diferentes abordagens de Inteligência Computacional.

Plano de Ensino

Conteúdo Programático

A disciplina está organizada em 7 unidades que cobrem desde os fundamentos da inteligência computacional até aplicações práticas em engenharia elétrica, com ênfase em séries temporais e redes neurais.

Plano de Ensino – Unidade I – Fundamentos da Inteligência Computacional



Conceitos de Inteligência Artificial e Inteligência Computacional



Paradigmas de IA



Aprendizado supervisionado e não supervisionado



Redes neurais artificiais



Lógica fuzzy



Sistemas neuro-fuzzy



Aplicações em Engenharia Elétrica

Plano de Ensino – Introdução às Séries Temporais

01

Conceitos fundamentais

02

Componentes de séries temporais: tendência, sazonalidade, ciclo e ruído

03

Séries univariadas e multivariadas

04

Pré-processamento: tratamento de valores ausentes, normalização e visualização

Plano de Ensino – Análise Estatística

- Autocorrelação (ACF) e Autocorrelação Parcial (PACF)
- Testes de estacionariedade: Dickey–Fuller Aumentado (ADF) e KPSS
- Transformações: diferenciação
- Seleção de variáveis

Plano de Ensino – Modelos Estatísticos

Modelos Clássicos

- AR
- MA
- ARMA
- ARIMA
- SARIMA

Modelos Multivariados

- ARIMAX
- SARIMAX
- VAR
- VARMAX

Seleção de Hiperparâmetros

critérios AIC e BIC

Plano de Ensino – Redes Neurais para Séries Temporais

01

Redes neurais artificiais e redes recorrentes

Conceitos e arquiteturas para dados sequenciais.

02

Problema do Vanishing Gradient

Desafios no treinamento de redes profundas e recorrentes.

03

LSTM (Long Short-Term Memory) e GRU (introdução)

Redes recorrentes especializadas para captura de dependências de longo prazo.

04

Preparação dos dados: janelas temporais e variáveis exógenas

Técnicas essenciais para o pré-processamento de séries temporais.

05

Treinamento e validação

Estratégias para otimização e avaliação de modelos de séries temporais.

Plano de Ensino – Avaliação dos Modelos

Nesta unidade, exploraremos os métodos essenciais para avaliar a eficácia e a robustez dos modelos de inteligência computacional.

Estratégias de Validação

- Holdout temporal
- Time Series Cross Validation
- Walk Forward Validation
- Nested Cross Validation

Métricas de Desempenho

- RMSE
- MAE
- MAPE
- R^2

Comparação de Modelos

Comparação entre modelos estatísticos e LSTM

Plano de Ensino – Aplicações da Inteligência Computacional

Aplicações em problemas de Engenharia Elétrica

1

Processamento e previsão de séries temporais

2

Sistemas de controle e automação

3

Processamento digital de sinais

4

Estudos de caso com dados reais

5

Análise comparativa entre técnicas

6

Tendências e desafios atuais

BIBLIOGRAFIA

Bibliografia Básica

BOX, G. E. P.; JENKINS, G. M.; REINSEL, G. C.; LJUNG, G. M. *Time Series Analysis: Forecasting and Control*. 5. ed. Wiley, 2015.

HAYKIN, S. *Neural Networks and Learning Machines*. 3. ed. Pearson, 2009.

NIELSEN, A. *Análise Prática de Séries Temporais: Predição com Estatística e Aprendizado de Máquina*. Alta Books, 2022.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. MIT Press, 2016.

Bibliografia Complementar

- HYNDMAN, R. J.; ATHANASOPOULOS, G. Forecasting: Principles and Practice. 3. ed. OTexts, 2021.
- BRUCE, P.; BRUCE, A. Estatística Prática para Cientistas de Dados. Alta Books, 2021.
- GÉRON, A. Mãos à Obra: Aprendizado de Máquina com Scikit-Learn, Keras & TensorFlow. 2. ed. Alta Books, 2021.
- JANG, J.-S. R.; SUN, C.-T.; MIZUTANI, E. Neuro-Fuzzy and Soft Computing. Prentice Hall, 1997.

CrITÉrios de Avaliação

Os critérios de avaliação para a disciplina são divididos em três componentes principais:

- **AT:** Avaliação Teórica (15/09/2026)
- **SD:** Seminário e discussão de artigo científico
- **PF:** Projeto Final (implementação e artigo científico)

A média final será calculada com base na seguinte fórmula ponderada:

$$MédiaFinal : AT \times 0,25 + SD \times 0,25 + PF \times 0,50$$

Uma prova optativa será oferecida em 17/11/2026 para aqueles que desejarem substituir a nota da Avaliação Teórica (AT).

Técnicas de Modelagem: Classificação e Hierarquia

Modelos Estatísticos Tradicionais

Métodos clássicos baseados em teoria estatística: Média Móvel, AR, MA, ARMA, ARIMA, SARIMA, Holt-Winters. Não aprendem com dados, seguem regras matemáticas pré-definidas.

Machine Learning (Aprendizado de Máquina)

Algoritmos que aprendem padrões a partir de dados: Regressão Linear, Random Forest, XGBoost, Support Vector Regression. Usam dados para otimizar parâmetros, mas com estrutura definida pelo usuário.

Inteligência Computacional


Técnicas bioinspiradas e adaptativas: Redes Neurais, LSTM, GRU, ANFIS (Neuro-Fuzzy), Algoritmos Genéticos, Computação Genética. Aprendem estrutura e parâmetros automaticamente dos dados.

Deep Learning

Redes neurais profundas com múltiplas camadas: LSTM, GRU, CNN 1D, Transformers. **Caso especial de IC** com capacidade de aprender representações hierárquicas complexas.

Hierarquia da Inteligência Artificial

CONCEITOS FUNDAMENTAIS



⚠ Zona de Sobreposição

Redes Neurais e Deep Learning pertencem simultaneamente ao Machine Learning e à Inteligência Computacional. A classificação depende do contexto e da literatura adotada.

Inteligência Artificial vs. Inteligência Computacional

Inteligência Artificial (IA)

Campo da ciência da computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que requerem inteligência humana.

- **Raciocínio e planejamento**
- **Percepção e reconhecimento de padrões**
- Processamento de linguagem natural
- **LSTM**
- **Séries Temporais**

Inteligência Computacional (IC)

Subconjunto da IA baseado em métodos bioinspirados e adaptativos para resolver problemas complexos e mal definidos.

- **Redes neurais artificiais**
- Lógica fuzzy
- **Algoritmos evolutivos**
- **LSTM**
- **Séries Temporais**

O que são Séries Temporais?

Uma série temporal é uma sequência de observações de uma variável coletadas em intervalos regulares de tempo. Cada ponto de dados depende dos valores anteriores, formando uma estrutura sequencial.

Características principais:



Dependência temporal:

valores passados influenciam valores futuros



Tendência:

movimento geral ascendente ou descendente



Sazonalidade:

padrões que se repetem em períodos regulares



Ciclos:

flutuações de longo prazo




Ruído:

variações aleatórias


Exemplos comuns: preços de ações, temperatura diária, consumo de energia, tráfego de rede, batimentos cardíacos.

Inteligência Computacional em Engenharia Elétrica




Sistemas de Potência

Previsão de carga, detecção de faltas, despacho econômico e estabilidade transitória com redes neurais e fuzzy.




Controle Inteligente

Controladores fuzzy e neuro-fuzzy para acionamentos elétricos, inversores de frequência e sistemas de tração.



Energias Renováveis

Previsão de geração eólica e solar, otimização de microrredes e gerenciamento de armazenamento com IC.



Qualidade de Energia

Classificação de distúrbios (afundamentos, harmônicos, flicker) usando redes neurais e transformada wavelet.

Séries Temporais em Engenharia Elétrica

A análise de séries temporais é fundamental em aplicações de engenharia elétrica:

Sistemas de Potência

- Previsão de demanda de energia elétrica
- Previsão de geração renovável (solar, eólica)

Qualidade de Energia

- Monitoramento de tensão e corrente
- Detecção de harmônicos e distúrbios

Máquinas e Equipamentos

- Monitoramento de vibração em motores
- Diagnóstico de falhas em equipamentos

Sistemas de Controle

- Controle adaptativo de processos
- Otimização de sistemas dinâmicos

Previsão de Geração de Energia Renovável

A integração de fontes renováveis exige previsão precisa de séries temporais.

Desafios específicos:

- Variabilidade da geração solar (nuvens, hora do dia)
- Variabilidade da geração eólica (velocidade do vento)
- Necessidade de previsão de curto e longo prazo
- Integração com a demanda de energia

Dados utilizados:

- Histórico de geração (potência em MW)
- Dados meteorológicos (radiação solar, velocidade do vento, temperatura)
- Informações de calendário (hora, dia da semana, estação)

Técnicas aplicadas:

- LSTM e GRU para capturar dependências temporais
- CNN 1D para extração de características
- Modelos híbridos (ANFIS) combinando lógica fuzzy com redes neurais
- VARMAX
- Ensemble de modelos para melhor precisão

Impacto:

- Melhor planejamento da geração
- Redução de desperdício de energia
- Maior estabilidade da rede
- Viabilidade econômica de fontes renováveis

Aplicações Práticas: Detecção de Anomalias em Redes Elétricas

Outra aplicação crítica é a detecção de anomalias e falhas em tempo real.

Cenários de aplicação:

- Detecção de curtos-circuitos
- Identificação de consumo anômalo (roubo de energia)
- Monitoramento de qualidade de energia
- Previsão de falhas em equipamentos

Como funciona:

1. Coleta contínua de dados de tensão, corrente e potência
2. Análise de padrões normais vs. anormais
3. Alertas em tempo real para operadores

Aplicações Práticas: Detecção de Anomalias em Redes Elétricas (cont.)

Técnicas utilizadas:

- Redes Neurais Recorrentes (LSTM/GRU) para detecção de padrões
- Autoencoder para identificação de anomalias
- ANFIS para sistemas de inferência fuzzy
- Algoritmos Genéticos para otimização de parâmetros

Benefícios:

- Redução de perdas técnicas
- Melhoria na confiabilidade do sistema
- Resposta rápida a problemas

Aplicações Práticas: Previsão de Demanda de Energia

Um dos casos mais importantes em engenharia elétrica é a previsão de demanda de energia.

Por que é importante?

- Otimizar a geração e distribuição de energia
- Reduzir custos operacionais
- Melhorar a estabilidade da rede
- Planejar investimentos em infraestrutura

Desafios:

- Padrões complexos (diários, semanais, sazonais)
- Eventos inesperados (feriados, clima extremo)
- Múltiplas variáveis correlacionadas (temperatura, umidade, dia da semana)

Técnicas aplicadas:

- Modelos estatísticos: ARIMA, SARIMA
- Machine Learning: Random Forest, XGBoost
- Inteligência Computacional: LSTM, GRU, ANFIS
- Deep Learning: Transformers, CNN 1D

Aplicação Prática: Identificação e Controle de Sistemas MIMO

Sistemas MIMO (Multiple-Input Multiple-Output) são sistemas com múltiplas entradas e saídas, comuns em engenharia elétrica e controle.

O Problema:

Sistemas físicos complexos têm comportamento não-linear e dinâmico difícil de modelar matematicamente. Métodos tradicionais requerem conhecimento prévio do sistema.

A Solução com Redes Neurais:

Uma rede neural é treinada para aprender o comportamento dinâmico do sistema físico em paralelo. A rede neural identifica o modelo do sistema observando:

- Entrada $u(t)$: sinais de controle aplicados
- Saída $y(t)$: resposta do sistema físico
- Erro $e(t)$: diferença entre a saída real e a predita

Aplicação Prática: Identificação e Controle de Sistemas MIMO (cont.)

Vantagens:

- Adaptação automática a mudanças no sistema
- Não requer modelo matemático prévio
- Capaz de lidar com não-linearidades
- Atualização contínua dos pesos da rede

Aplicações em Engenharia Elétrica:

- Controle de motores elétricos
- Identificação de parâmetros de transformadores
- Controle adaptativo de conversores de potência
- Sistemas de rastreamento de máxima potência (MPPT) em painéis solares